SIMULAÇÃO E MÉTODOS ANALÍTICOS · T2 – AVALIAÇÃO DE APRENDIZAGEM

Análise por simulação de um help desk de TI

Rede de filas com retorno: gargalo, melhoria e comparação.

Guilherme Guimarães Santos
Jully Anne Seyffert da Silva Jara

A realidade simulada: o help desk de TI

Três níveis com retorno · fila cheia = chamado perdido · tempos e probabilidades são premissas da equipe

01

N1 · Triagem

Recebe todos os chamados e resolve parte deles no primeiro contato.

2 servidores · atende em 6 a 10 min
Capacidade ilimitada
45% seguem para o N2

02

N2 · Especialista

Recebe o que o N1 escala e devolve ao N1 quando falta informação (10%).

2 servidores · atende em 20 a 40 min
Capacidade de 10 chamados
30% seguem para o N3

03

N3 · Desenvolvimento

Corrige e devolve ao N2 para validar a correção (20%).

1 servidor · atende em 30 a 60 min
Capacidade de 5 chamados
80% saem resolvidos

> Os chamados entram só pelo N1, a cada 4 a 8 minutos. Os dois retornos (N2 → N1 e N3 → N2) fazem a rede não ser uma linha reta: o chamado que volta disputa vaga de novo.

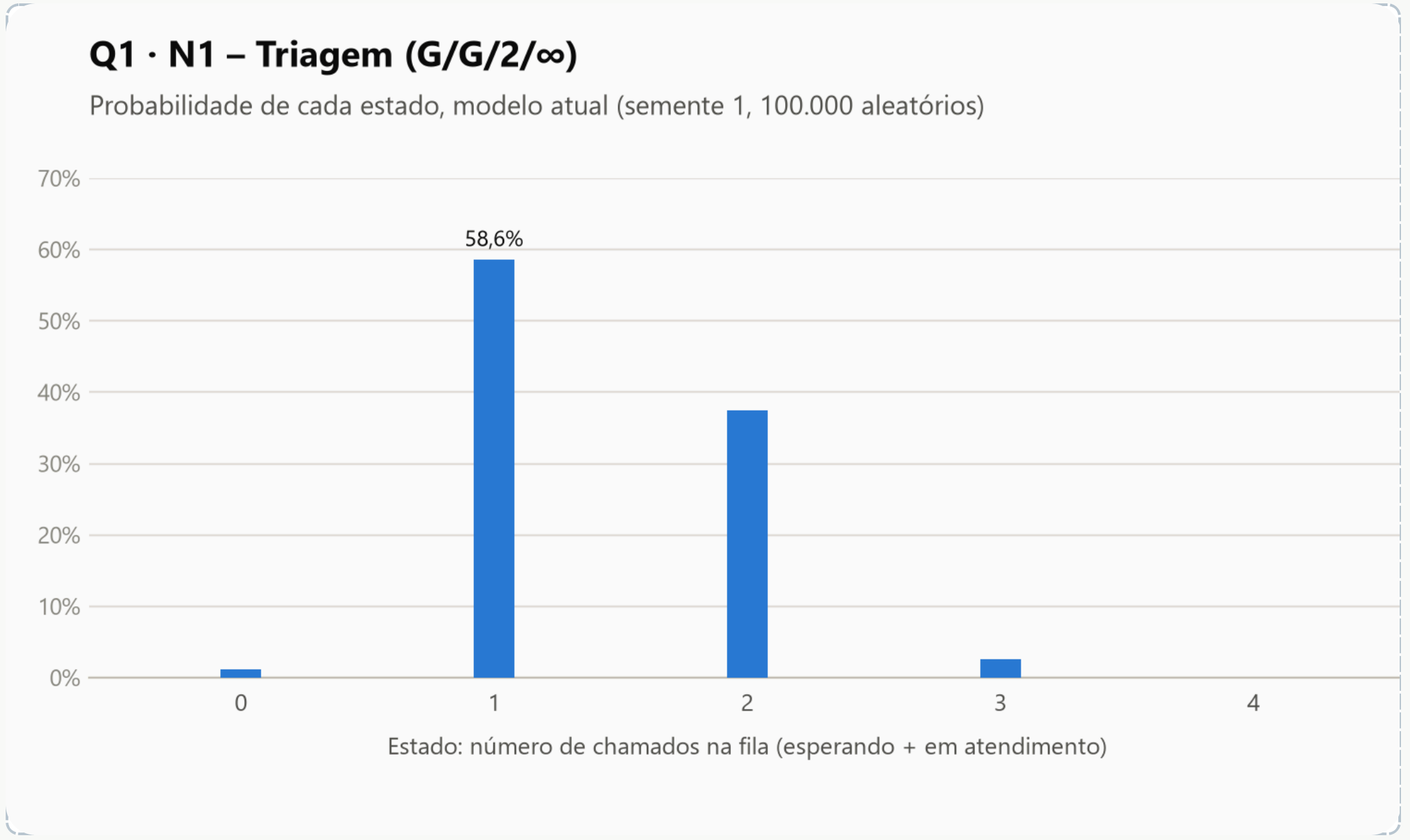
O modelo: rede de filas com retorno

Notação de Kendall G/G/c/K · c servidores · K = capacidade (fila + atendimento) · ∞ = ilimitada

Três filas ligadas por roteamento probabilístico, com dois retornos: Q2 → Q1 e Q3 → Q2.

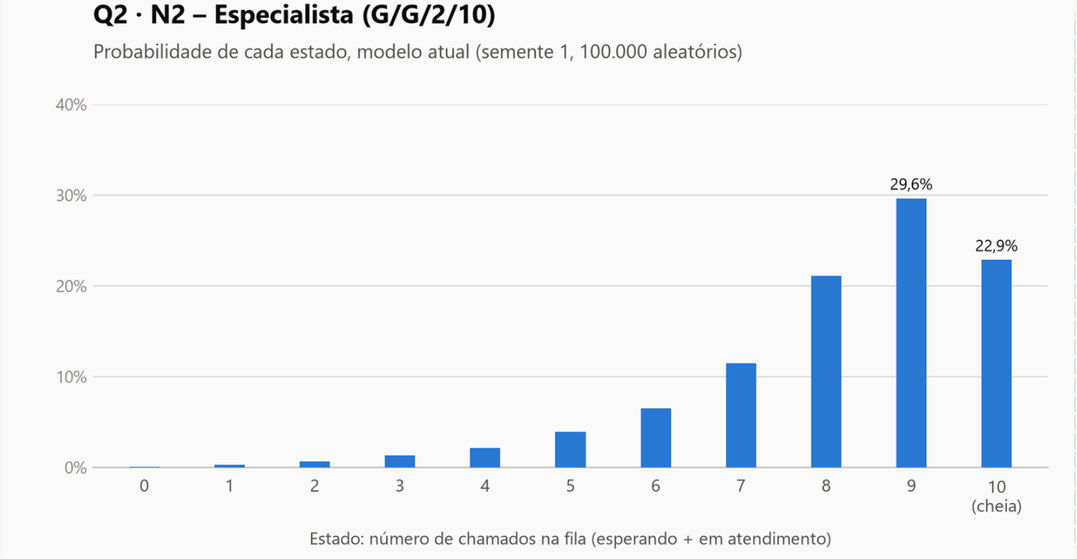
Roteamento
Q1 → Q2: 0,45
Q2 → Q3: 0,30
Q2 → Q1: 0,10
Q3 → Q2: 0,20

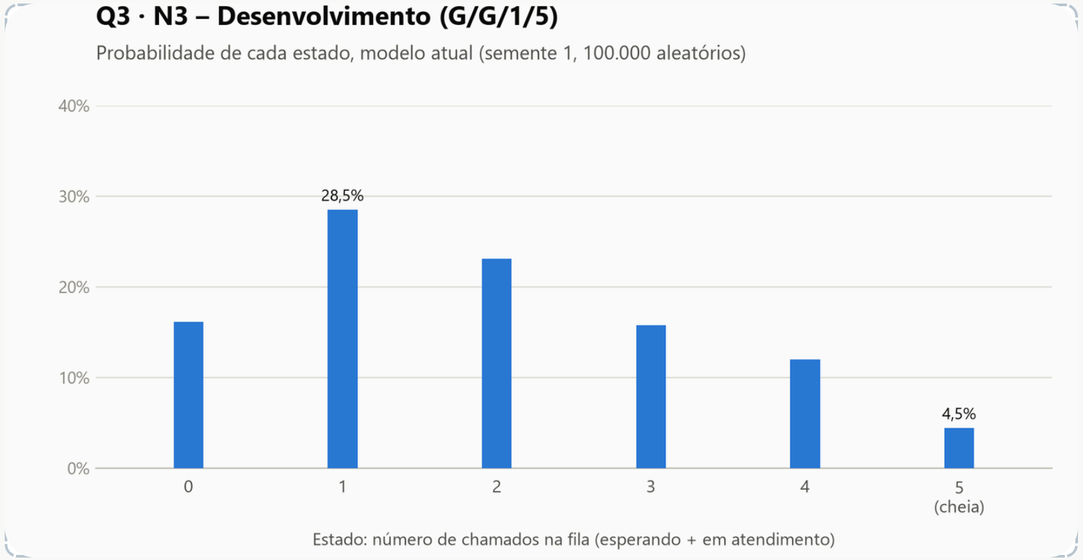
Parâmetros por fila (minutos)
Q1 · G/G/2/∞ · chega 4–8 · atende 6–10
Q2 · G/G/2/10 · atende 20–40
Q3 · G/G/1/5 · atende 30–60



Modelo atual: probabilidades dos estados

Simulação com 100.000 números aleatórios e semente 1 · Q2 passa 73,6% do tempo com 8 a 10 chamados





Modelo atual: índices de desempenho

Semente 1 · o Q2 está saturado: 99,8% de utilização, 2.057 perdas e 123 min de resposta

Fila	Perdas	N	D (cham/h)	U	W (min)
Q1	0	1,42	10,42	69,4%	8,2
Q2	2.057	8,17	3,99	99,8%	122,9
Q3	79	1,92	1,12	83,9%	103,2

No Q3 também há perdas (79) e espera longa (103 min). O Q1 tem folga: 69,4% de utilização e nenhuma perda.
N = chamados no sistema · D = vazão · U = utilização · W = tempo de resposta

Onde está o gargalo

Equações de tráfego: acima de 1 a fila satura. Só pôr servidor no Q2 move o gargalo para o Q3

Carga ρ = chegada ÷ capacidade (c·μ). O Q3 também passaria de 1, mas as perdas do Q2 deixam chegar menos chamados a ele.

0,70

CARGA DO Q1 · ABAIXO DE 1

Chegam 10,5 chamados/h
o N1 atende até 15/h

1,26

CARGA DO Q2 · ACIMA DE 1

Chegam 5,0 chamados/h
o N2 atende no máximo 4/h

1,13

CARGA DO Q3 · ACIMA DE 1

Chegam 1,5 chamados/h
o N3 atende no máximo 1,33/h

> Só pôr um servidor no Q2 não resolve: o problema migra para o Q3, que chega a 95% de utilização e cerca de 516 perdas (média de 5 sementes).

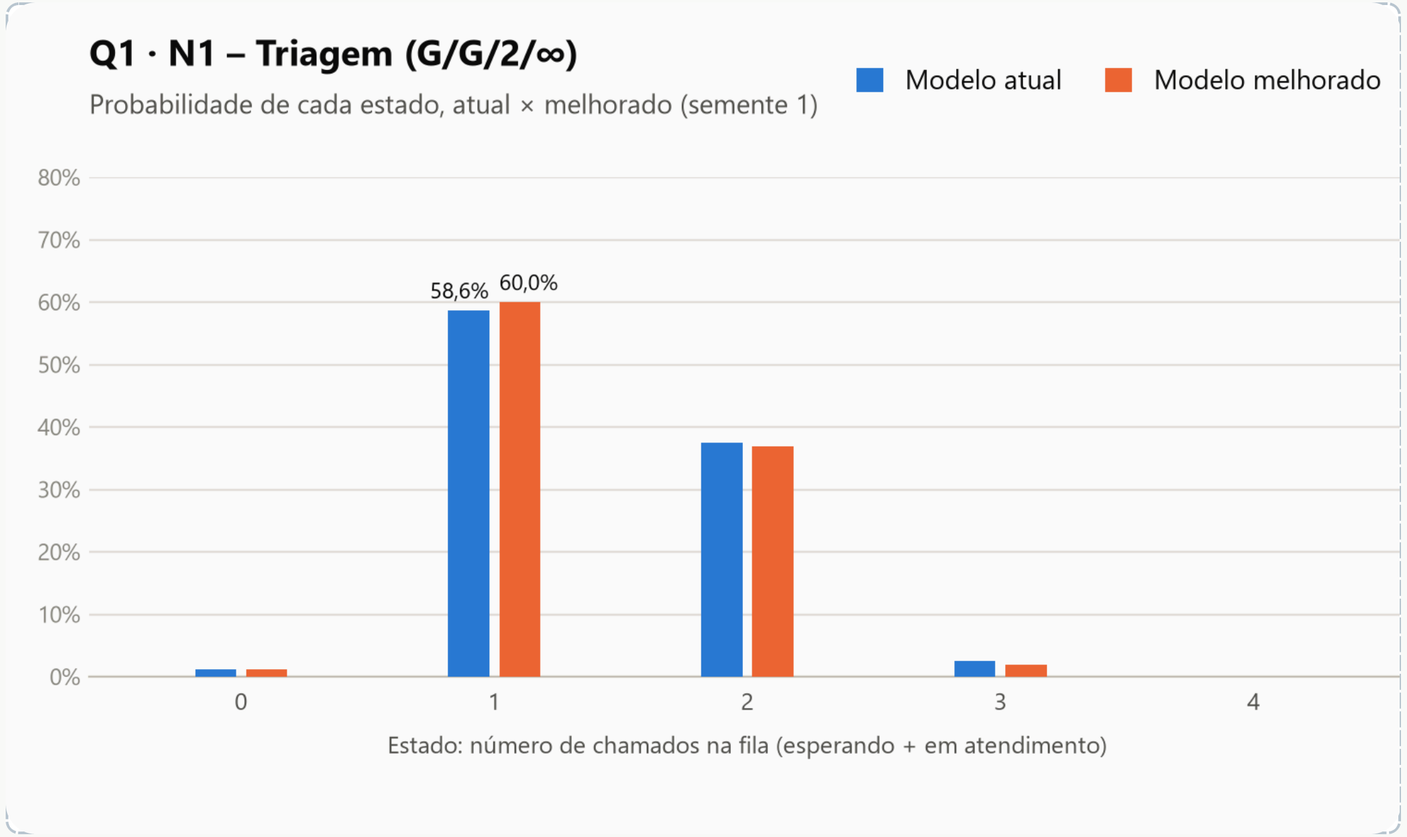
Proposta de melhoria

Parâmetro alterado: probabilidade de roteamento Q1 → Q2

O N1 passa a resolver 70% dos chamados no primeiro contato (antes 55%), com base de conhecimento e treinamento. Sem servidor nem capacidade a mais.

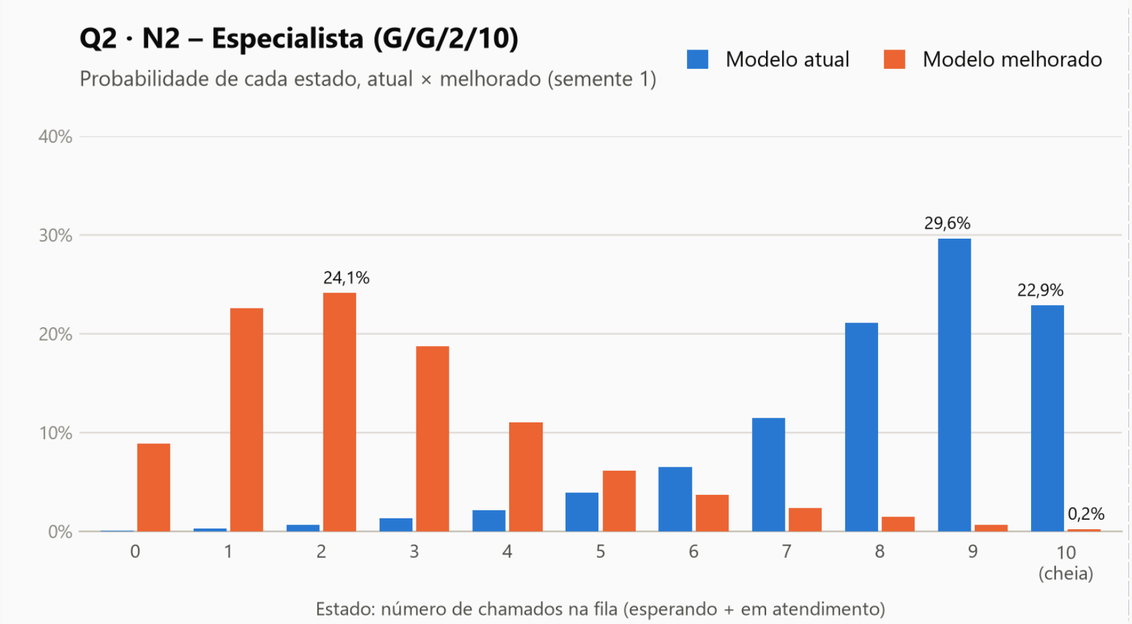
Q1 → Q2: 0,45 → 0,30

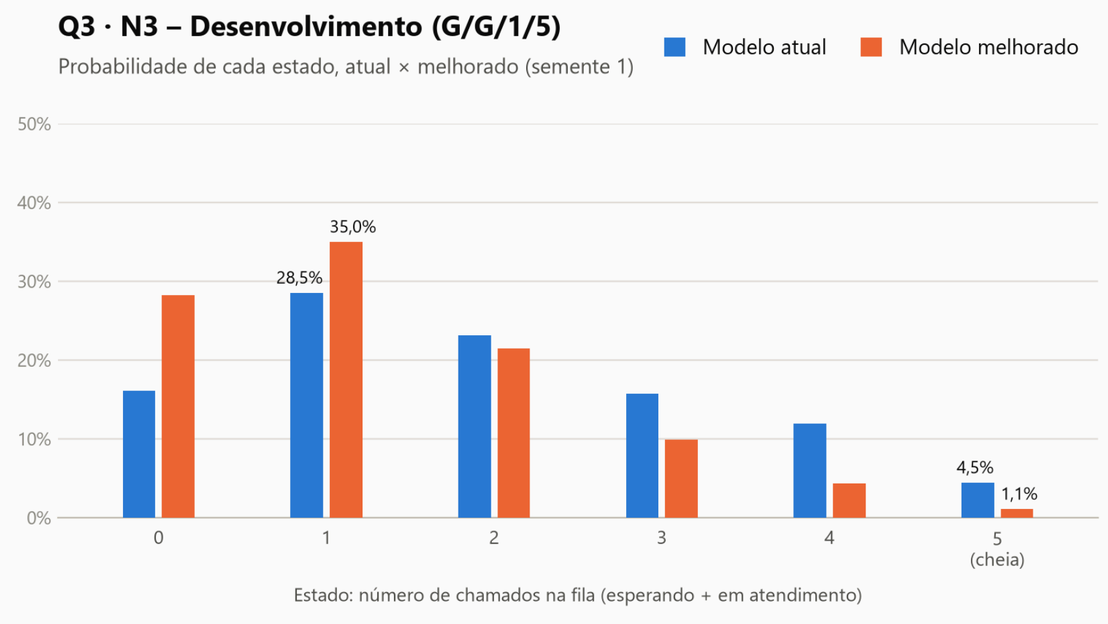
- Menor custo: não contrata ninguém, como orienta o M9.
- A carga do Q2 cai de 1,26 para 0,82 e a do Q3, de 1,13 para 0,74.
- Menos chamados escalam, então Q2 e Q3 perdem menos e respondem mais rápido.



Comparação: probabilidades dos estados

Q2 passa 73,6% do tempo com 8 a 10 chamados no atual e 76,5% do tempo com 1 a 4 no melhorado





Comparação: índices de desempenho

Q2 · semente 1 · a média de 5 sementes confirma o resultado

Q2 · INDICADOR	Atual	Melhorado	Variação
Perdas	2.057	**19**	-99,1%
População (N)	8,17	**2,61**	-68,1%
Vazão (D)	3,99 cham/h	**3,19 cham/h**	-20,1%
Utilização (U)	99,8%	**79,8%**	-20,1%
Tempo de resposta (W)	122,9 min	**49,0 min**	-60,1%

Na média de 5 sementes, as perdas do Q2 vão de 2.249 para 30 e o tempo de resposta, de 125 para 52 min.

-99%

de perdas no Q2
2.057 → 19

-60%

no tempo de resposta do Q2
123 → 49 min

Conclusões

Limites: premissas da equipe, meta de 70% de resolução no N1 e custo da melhoria não calculado

01

O gargalo era o N2: saturado, 2.057 perdas e 123 min.

A carga de 1,26 deixa a fila cheia 22,9% do tempo: todo chamado que chega nessa hora é perdido.

02

Resolver mais no N1 tirou carga do N2 sem contratar ninguém.

Com o roteamento Q1 → Q2 de 0,45 para 0,30, as perdas do Q2 caem 99% (2.057 → 19) e o tempo de resposta cai 60% (123 → 49 min).

03

Só pôr servidor no N2 empurraria o problema para o N3.

Com um 3º servidor no N2, o N3 passa a receber mais chamados e chega a cerca de 516 perdas (média de 5 sementes), contra 125 hoje.

Se o N1 resolver só 65%, ainda sobram cerca de 270 perdas no Q2: a meta de 70% precisa ser atingida.
Próximo passo: achar quanto de resolução no N1 zera as perdas e comparar com o custo de contratar.

Como conferimos os resultados

Validação do simulador e dos cálculos · média de 5 sementes junto com a semente 1

1 · ÍNDICES

Testados contra as 6 tabelas do exemplo do M9: os 6 casos batem.

testes_indices.py confere N, D, U e W das 6 tabelas do M9 (triagem, consultórios e laboratório, antes e depois das melhorias).

2 · SIMULADOR

Comparado com o simulator.jar: 30 comparações dentro do critério.

conferencia_jar.py roda os dois modelos nos dois simuladores, com as sementes 1 a 5. N, D, U e W diferem no máximo 2,2%.

3 · TRÁFEGO

Equações de tráfego batem com a utilização simulada.

equacoes_trafego.py resolve as equações sem simulação. No modelo melhorado a carga bate: 0,69 / 0,82 / 0,74 no papel e 0,69 / 0,82 / 0,73 na simulação.

> Os scripts estão na pasta do T2: qualquer pessoa pode repetir essas conferências.
> Na planilha, os índices são fórmulas e batem com os do script.